LAPORAN HASIL EKSPERIMEN

Single Perceptron dan Multilayer Perceptron (MLP)

Pengaruh Fungsi Aktivasi dan Learning Rate terhadap Mean Squared Error

Identitas	Keterangan
Mata Kuliah	Sistem Kecerdasan Buatan
Program Studi	Magister Sistem Informasi
Perguruan Tinggi	Telkom University
Nama Mahasiswa	Yoga Arfiansyah Firdaus
NIM	202022610037
Dosen Pengampu	Dr. Seno Adi Putra, S.Si., M.T

Tahun Akademik 2026

Ringkasan Eksekutif

Laporan ini membahas eksperimen Single Perceptron dan Multilayer Perceptron (MLP) untuk mengamati pengaruh fungsi aktivasi dan learning rate terhadap nilai Mean Squared Error (MSE). Eksperimen Single Perceptron dijalankan selama 500 epoch per konfigurasi, sedangkan MLP selama 5.000 epoch. Pada skenario fungsi aktivasi, learning rate dijaga sebesar 0,10. Pada skenario learning rate, fungsi aktivasi ditetapkan SIGMOID dan nilai learning rate yang dibandingkan adalah 0,01; 0,10; dan 0,50.

Hasil pencatatan menunjukkan bahwa Single Perceptron dengan STEP dan learning rate 0,10 mencapai MSE akhir 0,000000. Untuk Single Perceptron dengan SIGMOID, learning rate 0,50 menghasilkan MSE akhir 0,012232. Pada MLP, SIGMOID menghasilkan MSE akhir 0,252109 pada learning rate 0,10, sedangkan learning rate 0,50 menghasilkan MSE akhir 0,000907. Hasil tersebut berlaku untuk konfigurasi dan implementasi yang diuji; validasi algoritma dan evaluasi pada data uji terpisah tetap diperlukan sebelum menarik klaim yang lebih luas.

1. Pendahuluan

1.1 Latar Belakang

Perceptron merupakan salah satu model dasar jaringan saraf tiruan. Single Perceptron menggunakan satu unit komputasi utama, sedangkan MLP memiliki lapisan tersembunyi sehingga dapat memodelkan hubungan yang lebih kompleks. Dalam proses pelatihan, fungsi aktivasi menentukan transformasi nilai masukan bersih menjadi keluaran neuron, sementara learning rate mengatur besar langkah pembaruan bobot.

Perbedaan fungsi aktivasi dan learning rate dapat mempengaruhi pola konvergensi serta kesalahan prediksi. Oleh karena itu, eksperimen ini membandingkan sejumlah konfigurasi dan mengamati perubahan MSE selama pelatihan.

1.2 Tujuan

- Menganalisis pengaruh fungsi aktivasi terhadap MSE pada Single Perceptron dan MLP.
- Menganalisis pengaruh learning rate terhadap MSE pada Single Perceptron dan MLP.
- Membandingkan pola perubahan MSE berdasarkan hasil pencatatan eksperimen.
- Menyusun kesimpulan dengan mempertimbangkan batasan metrik dan konfigurasi yang digunakan.

2. Metodologi Eksperimen

2.1 Parameter Eksperimen

Aspek	Single Perceptron	MLP
Jumlah catatan hasil	4.500 baris	30.000 baris
Epoch per konfigurasi	500	5.000
Fungsi aktivasi	STEP, SIGMOID, TANH	SIGMOID, TANH
Learning rate	0,01; 0,10; 0,50	0,01; 0,10; 0,50
Metrik evaluasi	MSE	MSE

2.2 Skenario Pengujian

Skenario pertama menguji fungsi aktivasi dengan learning rate tetap sebesar 0,10. Pada Single Perceptron, fungsi yang dibandingkan adalah STEP, SIGMOID, dan TANH; pada MLP, fungsi yang dibandingkan adalah SIGMOID dan TANH. Skenario kedua menguji learning rate 0,01; 0,10; dan 0,50 dengan fungsi aktivasi SIGMOID.

2.3 Metrik Evaluasi

Mean Squared Error (MSE) mengukur rata-rata kuadrat selisih antara target dan keluaran prediksi. Secara umum, MSE yang lebih rendah menunjukkan kesalahan prediksi yang lebih kecil pada data dan prosedur pengukuran yang digunakan.

$$\mathbf{MSE = (1/n) \times \Sigma\ (target_i - prediksi_i)^2}$$

Catatan implementasi: program Single Perceptron mencatat MSE berdasarkan prediksi sebelum pembaruan bobot pada contoh pelatihan. Karena itu, angka MSE perlu dibaca sesuai urutan perhitungan program dan sebaiknya dikonfirmasi kembali dengan evaluasi setelah pelatihan selesai.

3. Hasil dan Analisis Single Perceptron

3.1 Pengaruh Fungsi Aktivasi

Fungsi aktivasi	MSE awal	MSE epoch 500	MSE terendah tercatat
STEP	0,500000	0,000000	0,000000 (epoch 6)
SIGMOID	0,241436	0,059442	0,059442 (epoch 500)
TANH	0,329376	0,089752	0,089731 (epoch 78)

Pada learning rate 0,10, STEP mencapai MSE nol pada epoch ke-6 dan mempertahankan nilai tersebut hingga akhir pencatatan. SIGMOID menurunkan MSE dari 0,241436 menjadi 0,059442. TANH menurunkan MSE dari 0,329376 menjadi 0,089752, dengan nilai minimum tercatat 0,089731 pada epoch ke-78. Berdasarkan MSE akhir, STEP memberikan hasil terendah pada konfigurasi ini.

Hasil tersebut tidak membuktikan bahwa STEP selalu lebih unggul. Performa bergantung pada data, aturan pembaruan bobot, inisialisasi, dan implementasi fungsi aktivasi. MSE nol perlu dikonfirmasi melalui pengujian prediksi setelah pelatihan.

3.2 Pengaruh Learning Rate

Learning rate	MSE awal	MSE epoch 500	Penurunan MSE*
0,01	0,239743	0,177244	26,07%
0,10	0,241436	0,059442	75,38%
0,50	0,249309	0,012232	95,09%

Dengan fungsi aktivasi SIGMOID, learning rate 0,01 menghasilkan penurunan MSE paling kecil dalam 500 epoch. Learning rate 0,10 menghasilkan penurunan yang lebih besar, sedangkan learning rate 0,50 menghasilkan MSE akhir terendah, yaitu 0,012232. Dalam rentang yang diuji, learning rate yang lebih tinggi berkaitan dengan perbaikan MSE yang lebih besar.

*Persentase penurunan dihitung dari (MSE awal − MSE akhir) / MSE awal × 100%. Temuan ini terbatas pada nilai learning rate yang diuji dan tidak berarti nilai yang lebih tinggi selalu lebih baik.

4. Hasil dan Analisis Multilayer Perceptron (MLP)

4.1 Pengaruh Fungsi Aktivasi

Fungsi aktivasi	MSE awal	MSE epoch 5.000	Penurunan MSE*
SIGMOID	0,252592	0,252109	0,19%
TANH	0,402520	0,264240	34,35%

Pada learning rate 0,10, SIGMOID memiliki MSE awal dan MSE akhir yang lebih rendah dibandingkan TANH. MSE akhir SIGMOID adalah 0,252109, sedangkan TANH 0,264240. Walaupun penurunan relatif TANH lebih besar, SIGMOID menyisakan kesalahan akhir yang lebih kecil. Ini menunjukkan bahwa penurunan relatif dan nilai kesalahan akhir mengukur aspek yang berbeda.

4.2 Pengaruh Learning Rate

Learning rate	MSE awal	MSE epoch 5.000	Penurunan MSE*
0,01	0,250476	0,250249	0,09%
0,10	0,252592	0,252109	0,19%
0,50	0,262217	0,000907	99,65%

Pada MLP dengan SIGMOID, learning rate 0,01 dan 0,10 menunjukkan perubahan MSE yang kecil selama 5.000 epoch. Sebaliknya, learning rate 0,50 menghasilkan MSE akhir sebesar 0,000907. Perbedaan yang besar ini menunjukkan bahwa learning rate berpengaruh pada hasil pelatihan dalam konfigurasi ini. Namun, perubahan yang sangat tajam perlu diperiksa dengan meninjau pembaruan bobot semua layer, perhitungan gradien backpropagation, turunan fungsi aktivasi, dan konsistensi perhitungan MSE.

*Persentase penurunan dihitung dari nilai MSE awal dan MSE akhir yang tercatat. Angka ini mendeskripsikan perubahan selama pelatihan, bukan ukuran performa pada data yang tidak pernah dilihat model.

5. Perbandingan dan Pembahasan Umum

Skenario	Konfigurasi dengan MSE akhir terendah	MSE akhir
Single Perceptron – fungsi aktivasi	STEP, learning rate 0,10	0,000000
Single Perceptron – learning rate	SIGMOID, learning rate 0,50	0,012232
MLP – fungsi aktivasi	SIGMOID, learning rate 0,10	0,252109
MLP – learning rate	SIGMOID, learning rate 0,50	0,000907

Secara umum, hasil memperlihatkan bahwa perubahan fungsi aktivasi maupun learning rate dapat menghasilkan pola pembelajaran yang berbeda. Single Perceptron dengan STEP menghasilkan MSE akhir nol pada skenario aktivasi, sedangkan MLP dengan SIGMOID dan learning rate 0,50 menghasilkan MSE akhir 0,000907 pada skenario learning rate.

Nilai MSE dari Single Perceptron dan MLP tidak boleh dibandingkan sebagai bukti langsung bahwa satu arsitektur lebih unggul, karena jumlah epoch dan konfigurasi model berbeda. Selain itu, MSE pelatihan saja tidak cukup untuk mengukur generalisasi. Untuk perbandingan yang lebih kuat, kedua model perlu diuji dengan data uji yang sama dan prosedur evaluasi yang konsisten.

6. Kesimpulan

1. Fungsi aktivasi dan learning rate mempengaruhi nilai MSE yang tercatat selama pelatihan, tetapi pengaruhnya berbeda pada setiap model dan konfigurasi.
2. Pada Single Perceptron dengan learning rate 0,10, STEP menghasilkan MSE akhir terendah sebesar 0,000000. Pada pengujian learning rate dengan SIGMOID, learning rate 0,50 menghasilkan MSE akhir terendah sebesar 0,012232.
3. Pada MLP dengan learning rate 0,10, SIGMOID menghasilkan MSE akhir 0,252109, lebih rendah daripada TANH sebesar 0,264240. Pada pengujian learning rate dengan SIGMOID, learning rate 0,50 menghasilkan MSE akhir 0,000907.

4. Learning rate 0,50 memberikan hasil akhir terbaik dalam skenario pengujian learning rate yang dilakukan, tetapi hasil ini tidak dapat digeneralisasi bahwa learning rate yang lebih tinggi selalu lebih baik.
5. Kesimpulan akhir masih dibatasi oleh penggunaan MSE pelatihan dan belum adanya evaluasi data uji terpisah. Pemeriksaan implementasi algoritma, terutama pada MLP, serta pengujian setelah pelatihan diperlukan sebelum menyatakan konfigurasi terbaik secara umum.

7. Saran

- Verifikasi kembali perhitungan MSE dan pastikan prosedurnya konsisten untuk setiap konfigurasi.
- Audit implementasi backpropagation pada MLP, termasuk turunan fungsi aktivasi dan pembaruan bobot di seluruh layer.
- Lakukan pengujian dengan data uji terpisah dan laporkan metrik evaluasi tambahan bila sesuai dengan tugas.
- Ulangi eksperimen dengan beberapa inisialisasi bobot untuk melihat apakah hasil konsisten, terutama pada learning rate 0,50.
- Sertakan grafik MSE terhadap epoch dari workbook Excel sebagai lampiran atau gambar pada laporan akhir.

Lampiran: Sumber Data

Analisis numerik dalam laporan ini disusun dari berkas single_results.csv dan mlp_results.csv yang digunakan pada eksperimen, serta ringkasan grafik pada workbook Excel. Angka yang ditampilkan dibulatkan untuk memudahkan pembacaan.